

JB 준법 코파일럿

소비자가 오해하기 전에 — 작성 시점 오인 방지 준법자문 AI Agent · MVP 제안서

주제	준법자문가 AI Agent 서비스 개발	작성일	2026-06-13
참가	솔로 (개발: Claude 수행)	구동	1-커맨드 · 온프레미스
제약	무료/오픈소스 모델만 (Qwen2.5-7B)	검증	동작 MVP · 테스트 57건 통과

- 소비자 오인 시뮬레이터
- 작성시점 실시간 예방
- 준법 오토파일럿
- 온프레미스 · 오픈모델
- RAG + 룰엔진 + LLM

1 Summary

JB 준법 코파일럿은 대고객 금융 광고를 **작성하는 그 순간**, 고령자·금융초보·외국인 소비자가 그 문구를 **어떻게 오해하는지 1인칭으로 재현**해 보여주고, 규제 근거와 함께 수정안을 제시하며, 위반 초안을 **준법 통과** 까지 **자율 개선**하는 온프레미스 AI Agent다. 준법관리자는 전수 초벌심의 대신 **검토·승인**에 집중한다.

구분	요지
한 줄 정의	"소비자가 오해하기 전에" — 배포 전이 아니라 작성 시점 에 오인을 차단
핵심 차별점	소비자 오인 시뮬레이터 — 규제의 본질(오인 방지)을 페르소나 역할극으로 정면 공략 (해외 Saifr·PerformLine에도 없는 지점)
Agent 구조	판단(룰+LLM)·행동(수정·배포)·검증/개선(오토파일럿 자율 루프)·휴먼인더루프 승인
도입 가능성	100% 온프레미스·오픈모델 — 미공개 마케팅 자료를 외부 전송 없이 처리. 망분리 환경 구동
완성도	F1-F16 동작 MVP · 1분 구동 · 자동 테스트 57건 통과 · 본 제안서/기능명세서/설계서 정합

2 문제 정의 (Problem Definition)

2.1 현행 업무의 병목·리스크

- **사후·수작업 심의의 한계:** 은행 광고는 게시 전 준법감시인 사전심의가 의무(금소법 §22, 은행연합회 광고심의규정)지만, 현실은 "초안 → 수일 대기 → 수작업 심의 → 반려·재작성 반복"의 왕복으로 적시성을 잃는다.
- **"합법이지만 오해를 부르는" 사각지대:** 규정 문구만 점검하면 통과해도, 고령자·외국인이 실제로 오해하는 표현은 걸러지지 않아 **불완전판매·민원**으로 이어진다. 규제의 본질은 "오인 방지"인데 기존 심의는 "표현 점검"에 머문다.
- **제재 리스크 직결:** 금소법 §22 위반 광고는 과징금·기관제재 대상. 광고 1건이 분쟁의 시작점이 될 수 있다.

2.2 대상 사용자와 상황


사용자	상황	핵심 Pain
마케팅·지점 담당자	광고·안내문 초안 작성 중	심의 대기로 적시성 손실, 무엇이 문제인지 작성 중엔 알 수 없음
준법관리자(준법감시부)	전수 콘텐츠 초벌 심의	반복 검출·근거 탐색·수정안 작성의 수작업 부하, 인력 한정
(간접) 금융소비자	배포 콘텐츠 열람	취약계층의 오인 → 불완전판매 피해

2.3 JB 관점의 중요도

전북·광주은행은 **지역 밀착 마케팅** 빈도가 높고, 전북 지역 **외국인 거주자 고객** 비중이 늘어 다국어 콘텐츠 수요가 커지는 반면 심의 인력은 한정적이다. 입력(초안)·출력(심의·승인)·사용자·프로세스 접점이 명확해 **그대로 내부 시스템 과제로 전환 가능**하며, 본 MVP가 그 실현성을 동작으로 증명한다.

3 제안 솔루션 개요 (Solution Overview)

작성 시점에 작동하는 **온프레미스 준법 AI Agent**. 명시적 파이썬 파이프라인이 ①콘텐츠 유형 분류 → ②규제 근거 검색(RAG) → ③롤엔진(결정적) → ④LLM 심의(취약스) → ⑤**소비자 오인 시뮬레이터** → ⑥리포트 종합 → ⑦⑧준법관리자 승인·감사로그로 흐른다.



신뢰 모델 — 룰엔진이 권위, LLM은 보조

판정의 뼈대는 결정적 룰엔진(YAML 공개)과 RAG 인용이고, LLM은 뉘앙스·역할극을 담당하되

인용은 검색된 조항으로 제한

되고 출력은 룰엔진이 검증한다. 환각이 등급을 좌우할 수 없는 구조 — 은행이 실제로 받아들일 수 있는 유일한 형태.

4 주요 기능 정의 (Key Features)

★ 소비자 오인 시뮬레이터

헤드라인

👴 72세 · 👧 20대 · 🌐 외국인 페르소나가 광고를 1인칭으로 읽고 오해 → 위험 오해 + 유발 문구 + 규제 조항 연결. 화면을 열면 가장 먼저 보인다.

준법 오토파일럿 Agent

위반 초안을 심의 → 고쳐쓰기 → 재심의로
🟢 통과까지 자율 반복. 합격은 룰엔진이 검증, 게시는 사람 승인.

작성시점 실시간 예방

타이핑을 멈추면 즉시 룰 검사(0.03초)
→ LLM 심의 보강. 위험 문구 자동 밀줄.

규제 근거 RAG + 인용

모든 지적에 금소법·심사지침 등 조항 출처 인용. 근거 부족 시 "근거 불충분" 표기.

내부 심의기준(내규)

준법부가 평문으로 내규 입력 → AI가 룰로 변환 → 법규와 함께 적용 (비개발자·[내규]).

규제 자동 추적

규제 피드 변경 감지 → 영향 콘텐츠 분석
→ 룰 자동 제안(사람 승인). 운영: 법제처 OpenAPI.

승인 + 감사로그

준법관리자 승인/반려. 누가·언제·어떤 근거로를 영구 기록 (내부통제·검사 대응).

마케팅 배포 Last-Mile

승인 콘텐츠 → 채널(푸시·SMS·이메일·SNS·CRM) 자동 연계. 미승인 차단. 운영: FCM/SNS/알림톡.

다국어 + 신뢰도 방어

승인본 외국어 생성·재심의(직역 오역 검출). 비-한/영은 신뢰도 플래그+사람검토.

그 외: 상품 DB 연동(상품코드→조건 자동 주입, 코어뱅킹 슬롯) · 수정안 원클릭 적용 · 콘텐츠 유형 분류 라우팅. 전체 F1-F16 구현, 자동 테스트 57건 통과. 상세는 함께 제출하는 **기능명세서** 참조.

5 데이터 및 기술 활용 (Data & Tech Plan)

레이어	선택	비고 / 라이선스
LLM	Qwen2.5-7B-Instruct (Ollama 로컬 서빙)	Apache 2.0 · 한국어+다국어 강함 · GPU 8-12GB · 14B 교체는 환경변수 1개
RAG	어휘 검색 기본 + BGE-m3 임베딩(선택)	MIT · 의존성 0 즉시 구동, 인터페이스 분리로 교체 용이
룰엔진	YAML + 정규식 (결정적·설명가능)	코드 수정 없이 룰 추가, 내규는 자연어→룰 변환
백엔드/저장소	FastAPI(비동기 병렬) / SQLite	MIT/BSD · 본선 PostgreSQL 전환 용이
프론트	정적 SPA (바닐라 JS)	빌드 불필요, 1-커맨드 실행 · 본선 Next.js

5.1 데이터 출처 · 정직성

- 실제 규제 기반:** 금소법 §22, 표시광고법 §3, 자본시장법 §57, 표시·광고 심사지침, 은행연합회·금융투자협회 규정 — 국가법령정보센터(법령은 저작권법 §7 비보호 저작물). 내용은 실제 규제의 취지를 정확히 반영.
- 시연용(가상) 데이터 명시:** MVP 코퍼스는 요약·재구성본(12조항)이며, **JB 내부기준·규제 피드·상품 카탈로그는 가상 데이터**(시연용)다. 운영 시 원문 전문 수록·법무 검증 + 실제 내규/법제처 OpenAPI/코어뱅킹 API로 교체하는 어댑터 슬롯으로 설계.
- 상용 API 미사용:** 대회 제약(무료/오픈소스) 및 온프레미스 원칙 준수. 외부 전송 0.

5.2 환각·책임·보안 방어 (설계에 내장)

- 환각:** 인용 화이트리스트(검색 조항 제한)·quote 원문 검증·룰엔진 권위·비영여권 신뢰도 플래그. RAG는 법률 **참조 그래프 확장**으로 교차참조 맥락 보완(단, 등급 권위는 룰엔진).
- 망분리(Air-gap):** 심의 코어는 내부망 격리(심의 데이터 외부 유출 0). 외부 연동(규제 추적·배포·상품DB)은 **망연계 게이트웨이(DMZ) 경유** — 실시간 크롤/직접 발송이 아닌 배치·단방향 전송.
- 책임·확증편향:** AI는 1차심의·권고, 최종 판단·책임은 검토자. 승인 전 **AI 불확실 경고 + "원문 직접 검토" 확인 강제**로 무지성 승인 억제. 자율 자동화(규제 룰·자가 개선·배포)는 모두 사람 승인 게이트 + 감사로그.
- 모델 노후화:** 모델 교체가 환경변수 1개 — 오픈모델 발전을 즉시 수용.

6 사용자 시나리오 / 유즈케이스 (User Scenario)

준법감시부·마케팅부의 하루 — 작성 시점 예방부터 배포 연계까지 한 흐름:

- 1. [상시] 규제 자동 추적 — 새벽에 규제 피드(운영: 법제처 OpenAPI)에서 개정 감지 → 영향 콘텐츠 분석 → 룰 변경 제안. 준법감시인이 검토·승인으로 룰셋 최신화.
- 2. [작성] 실시간 예방 — 담당자가 초안 작성. 상품코드 선택 시 코어뱅킹에서 조건 자동 주입. 멈추면 즉시 룰 검사 → LLM 보강. 헤드라인에 "👤 72세가 '원금 보장이니 안전하네'로 오해 🚫"가 떠 작성 중에 위험 인지.
- 3. [자가 개선] — [🚀 자동 개선]으로 통과까지 자율 수정(미수렴 시 사람 에스컬레이션). 법규 + JB 내규 동시 적용.
- 4. [검토·승인] — 준법감시인이 AI 1차심의·페르소나 오해·규제 인용을 근거로 승인/반려. 결정이 감사로그에 영구 기록.
- 5. [배포 연계] — 승인 즉시 채널(푸시·SMS·이메일·SNS·CRM)로 자동 발송(미승인 차단). "AI 자동개선 → 사람 승인 → 시스템 배포"가 분리 기록되어 금감원 검사 대응.
- 6. [다국어] — 전북 외국인 고객용 외국어 버전을 승인본에서 자동 생성·재심의. 비·한/영은 신뢰도 플래그+사람검토.

전 과정 온프레미스 + 휴먼인더루프

모든 자동화(규제 룰·자가 개선·배포)는 사람의 승인을 거친다. AI는 1차심의·권고만,

배포 결정 권한은 항상 준법관리자

에게 있어 책임 경계가 명확하다.

7 기대 효과 및 향후 확장성 (Expected Impact)

7.1 기대 효과

축	효과
업무효율	준법관리자의 초벌 심의(검출·근거 탐색·수정안 작성)를 자동화 → 건당 검토를 "읽고 판단"으로 축소. 다국어 심의의 한계비용 ≈ 0.
리스크 감소	배포 전 전수 1차심의 + 일관된 기준 + 오인 시뮬레이터 로 "합법이지만 오해 유발" 영역까지 가시화 → 불완전판매·민원 감소.
고객가치	취약계층(고령·초보·외국인) 관점의 오해를 사전 제거 → 명확·공정한 정보, 신뢰 제고.
수익기회	심의 리드타임 단축 → 마케팅 적시성 회복(시즌·금리 이벤트), 콘텐츠 생산량 확대.
그룹 AX	"반복 판단은 AI가 1차, 사람은 최종 판단" — 그룹 디지털 전환이 지향하는 업무방식 전환의 전형.

7.2 확장 경로 (PoC → 서비스화)

PoC	준법감시부와 과거 심의 사례 50~100건 블라인드 비교 (AI vs 사람 일치율·정밀도/재현율)
파일럿	1개 부서 신규 콘텐츠 병행 적용 → 검출률·시간 절감 측정, 점수 가중치 캘리브레이션
내부 적용	전 계열사(전북·광주은행·캐피탈·자산운용) 광고심의 표준 도구, 내규 정식 등재
서비스화	콘텐츠 외 약관·상품설명서·콜센터 스크립트·공시로 확대, 그룹 공통 Compliance AI 플랫폼
운영 연동	규제 피드→법제처 OpenAPI · 발송→FCM/SNS/알림톡 · 상품→코어뱅킹 API (어댑터 교체)

7.3 확장 축

- **계열사:** 롤·코퍼스의 `types` 라우팅 구조가 그대로 확장 단위 — 은행 광고 → 캐피탈(대출성) → 자산운용(투자광고).
- **콘텐츠 유형·언어·채널:** 카드·이벤트·보험은 YAML 룰 추가만으로, 언어는 베트남어·중국어로, 채널은 사내 결재·CMS 플러그인으로 확장.

JB 준법 코파일럿 MVP 제안서 · 2026-06-13 · JB금융그룹 Fin:AI Challenge 지정주제2 Compliance AI
 함께 제출: 기능명세서 · 사용 설명서 · 로직 설명서 · 설계 문서 · MVP 코드(GitHub) · 브라우저 인쇄(Ctrl+P) → PDF로 저장.