

JB 준법 코파일럿 — 기능명세서

소비자 오인 방지 중심 준법자문 AI Agent 서비스

주제 준법자문가 AI Agent 서비스 개발 (지정주제2)

작성일 2026-06-11

산출물 동작하는 MVP(코드+README) · 본 기능명세서 · 시연 시나리오

제약 준수 무료·오픈소스 모델만 사용 · 100% 온프레미스

1 서비스 개요

대고객 금융 콘텐츠(광고·안내문)를 **작성 시점부터** AI가 1차 심의하고, **소비자(고령자·금융초보·외국인)가 어떻게 오해하는지 시뮬레이션**해 위험을 드러내며, **규제 근거를 인용한 수정안**을 제시한다. 준법관리자는 **검토·승인**만 수행하고 전 과정이 감사로그로 남는다. 외부 API 없이 오픈모델로 구동되는 **온프레미스 AI Agent**.

1.1 해결하려는 문제 (은행 제시 현행·한계 기반)

구분	내용
현행	대고객 콘텐츠 전반을 준법관리자가 대부분 수작업 심의. 외국어 콘텐츠도 동일 인력·동일 방식. 심의 지연 → 배포 지연 → 마케팅 적시성 손실. 심의 품질 편차 와 휴먼에러.
한계	준법 심의가 병목 이 되어 콘텐츠 적시성·확장성 제한. 다국어·다채널 확장 시 심의 리소스 선형 증가 . 규제 변경의 즉시 반영 어려움.
본질	금융 광고 규제(금소법 §22 등)의 목적은 "표현 적발"이 아니라 소비자 오인·기만 방지 다. 기존 수작업·표현매칭 도구는 "실제 소비자가 어떻게 오해하는가"를 직접 다루지 못한다.

1.2 대상 사용자와 사용 상황

사용자	사용 상황	제공 가치
마케팅·상품·지점 담당자	광고/SNS/안내문 초안 작성 중 — 타이핑을 멈추거나 붙여넣는 순간 자동 심의	배포 전 사전 차단, 수정안 원클릭 적용, 심의 대기 없는 작성
준법관리자(준법감시부)	AI 1차심의가 끝난 콘텐츠의 검토·승인	전수 초벌심의 자동화 → 판단 업무에 집중, 일관된 기준, 감사추적
(간접) 금융소비자	배포된 콘텐츠 열람	오인 유발 표현이 제거된 명확·공정한 정보

운영 시나리오 (준법감시부·마케팅부의 하루) — 작성 시점 예방부터 배포 연계까지 한 흐름:

- [Phase 0 · 상시] 규제 자동 추적 F14** — 매일 새벽 규제 피드(운영: 법제처 OpenAPI)에서 고시·법령 개정을 감지 → 영향 콘텐츠 분석 → 룰 변경 자동 제안. 준법감시인이 검토·**승인**하면 룰셋 최신화. ("사람이 일일이 찾아 놓아야 하나" 해소 — 단 적용은 사람 승인)
- [Phase 1 · 작성] 상품조건 자동 주입 + 실시간 예방 F16-F11-F5** — 담당자가 초안 작성, 상품코드 선택 시 코어뱅킹(운영 연동)에서 전체 조건 자동 주입. 멈추면 즉시 룰 검사(0.03초), 이어 LLM 심의·오인 시뮬레이터 보강. 헤드라인에 "👤 72세가

이렇게 오해한다"가 때 **작성 시점에** 위험 인지.

3. **[Phase 2 · 자가 개선]** **F12-F13** — [ 자동 개선]으로 통과까지 자율 수정(미수렴 시 사람 에스컬레이션). 법규 + JB 자체 **내규**(준법부가 평문 등록)를 함께 적용.
4. **[Phase 3 · 검토·승인]** **F8-F9** — [검토 전송] → 준법감시인이 AI 1차심의·페르소나 오해·규제 인용을 근거로 승인/반려. 결정이 감사로그에 영구 기록.
5. **[Phase 4 · 배포 자동 연계]** **F15** — 승인 즉시 채널(애플사·SMS·이메일·SNS·CRM, 운영: FCM/SNS/SendGrid/알림톡)로 자동 발송. 미승인 차단. "AI 자동개선 → 사람 승인 → 시스템 배포"가 **분리 기록**되어 금감원 검사 대응. ("승인 결과 자동 연계" 해소)
6. **[Phase 5 · 다국어]** **F10** — 전북 외국인 고객용 외국어 버전을 승인본에서 자동 생성·재심의. **한국어=주력 시장이므로 우선 배포**하고 다국어는 후속(생성·심의 한계비용 ≈ 0) — 영어 재심의가 한국어 발송을 지연시키지 않는다. **재심의 불통과 시 마케터·준법감시인에 알림 + 외국어 채널 배포 보류**. 비·한/영은 신뢰도 플래그 + 사람 검토 + KO 피벗으로 환각 방어.

전 과정 온프레미스 + 휴먼인터루프

모든 자동화(규제 룰·자가 개선·배포)는 사람의 승인을 거친다. 외부 연동(법제처·발송서버·코어뱅킹)은 어댑터로 분리되어 데모는 목/피드로 동작을 증명하고 운영에서 실연동으로 교체된다.

1.3 문제의 중요도 — 금융업·JB 관점

- **제재 리스크 직결**: 금소법 §22 위반 광고는 과징금·기관제재 대상. 광고 1건의 오인 표현이 불완전판매 분쟁으로 이어지는 구조적 리스크.
- **JB 특수성**: 전북·광주은행은 지역 밀착 마케팅 빈도가 높고, 전북 지역 **외국인 거주자 고객** 비중 증가로 다국어 콘텐츠 수요가 커지는 반면 심의 인력은 한정적.
- **서비스 과제 전환성**: 입력(콘텐츠 초안)·출력(심의 리포트·승인 상태)·사용자·프로세스 접점이 명확해 그대로 내부 시스템 과제로 전환 가능 — 본 MVP가 그 증명.

2 금융업무 연계 및 기대효과

2.1 업무 프로세스 접점 (As-Is → To-Be)

As-Is 기획 → 초안 작성 → (수일 대기) 준법 수작업 심의 → 반려·재작성 반복 → 승인 → 배포
▲ 병목·편차·적시성 손실

To-Be 기획 → 초안 작성 ☺ AI 실시간 심의·수정안 (작성 중 즉시, 무한 반복 무비용)
→  준법 오토파일럿: 위반 초안을 통과까지 자율 개선 (선택 - 수정 왕복 자동화)
→ 준법관리자 검토·승인 (AI 리포트 기반 판단만) → 배포가능 + 감사로그
→ (다국어) 승인본 기반 자동 생성 + 재심의

2.2 기대효과

측	기대효과
업무효율	준법관리자의 초벌 심의(표현 검출·근거 탐색·수정안 작성)를 자동화 → 건당 검토 시간을 "읽고 판단"으로 축소. 다국어 심의의 한계비용 ≈ 0.
리스크 감소	배포 전 전수 1차심의 + 일관된 룰 기준 → 휴먼에러·품질편차 감소. 오인 시뮬레이터로 "규정상 합법이지만 오해 유발" 영역까지 가시화.
고객가치	취약계층(고령·초보·외국인) 관점의 오해를 사전 제거 → 불완전판매·민원 감소, 신뢰 제고.
수익기회	심의 리드타임 단축 → 마케팅 적시성 회복(시즌·금리 이벤트 대응). 콘텐츠 생산량 확대 가능.
그룹 AX 부합	"사람이 하던 반복 판단을 AI가 1차 수행, 사람은 최종 판단" — 그룹 AX·디지털 전환이 지향하는 업무방식 전환의 전형적 사례.

2.3 규제·보안·개인정보·내부통제 고려 (설계에 내장)

- 데이터 주권:** 심의 대상(미공개 마케팅 자료·내부 심의기준)은 외부 전송 불가 정보 → **심의 코어는 내부망 격리·외부 API 미사용**(망분리 구동). 외부 연동(F14 규제추적·F15 배포·F16 상품DB)은 코어가 직접 통신하지 않고 **망연계 게이트웨이(DMZ) 경유**로 설계 — 심의 데이터 외부 유출 0 (\$5.1 3-zone).
- 개인정보:** 처리 대상은 콘텐츠 텍스트뿐, 고객 개인정보를 수집·저장하지 않음. 페르소나는 가상 프로필.
- 내부통제:** 모든 제출·승인·반려·번역이 감사로그(누가/언제/근거)로 기록 — 광고심의 기록 보존 의무 및 내부통제 점검에 대응.
- 책임소재:** AI는 1차심의·권고만 수행하고 **배포 결정 권한은 항상 사람(준법관리자)**에게 있는 Human-in-the-loop 구조로 책임 경계를 명확화.

3 차별점

차별점	내용
① 소비자 오인 시뮬레이터 헤드라인 기능	고령자·금융초보·외국인 페르소나가 광고를 1인칭으로 읽고 오해하는 과정을 재현 → 위험 오해 + 유발 문구 + 금소법 조항 연결. UI의 헤드라인 으로 배치해 화면을 열면 "이 광고를 소비자가 어떻게 오해하는지"가 가장 먼저 보인다. 기본 3종에 더해 전북 특화 페르소나 (농업인·소상공인)로 지역 고객(계절성 목돈·운전자금 대출 등)의 오인까지 재현. 해외 유사 제품(Saifr, PerformLine 등)에도 없는 지점이며, 규제의 본질(오인 방지)을 정면 공략.
② 작성시점 실시간 예방	사후 배치 심의가 아니라 작성 중(멈춤·붙여넣기) 자동 검사 → 병목·적시성 문제를 근본 해결.
③ 온프레미스·오픈모델	해외 제품은 영어권 규제 기반 SaaS. 한국어·한국 규제 + 온프레미스는 은행이 실제 도입 가능한 유일한 형태 .
④ 준법 오토파일럿 자율 에이전트	위반 초안을 심의→고쳐쓰기→재심의로 통과까지 자율 반복 하는 목표지향 에이전트. 합격 판정은 결정적 룰엔진이 검증해 LLM의 합격 위장(환각)을 차단하고, 최종 게시는 사람 승인을 거친다. "심의 도구"를 넘어 "통과시켜 주는 에이전트"로 — 평가 기준의 AI Agent 정의(판단·행동·검증/개선·종료조건)를 문자 그대로 구현. (검증: 46→82→88 자율 수렴)

4 AI Agent 설계 — 판단·행동·검증·개선 구조

단계	수행 내용
인지	콘텐츠 유형 분류(①) + 규제 근거 검색 RAG(②)로 맥락 수집
판단	룰엔진 결정적 판정(③) + LLM 뉘앙스 심의(④) + 오인 시뮬레이터의 페르소나 역할극→오해 판정(⑤)
행동	수정안 생성·치환, 고지문 추가(F7), 준법 오토파일럿 — 통과까지 자율 개선 루프(F12) (수정 전/후 비교 뷰 diff + 가독성 참고지표 병행 표시), 다국어 버전 생성(F10), 승인 시 배포가능 상태 전환
검증	수정 적용 후 자동 재심의 루프 , 번역본 재심의, 인용 화이트리스트·quote 원문 검증(환각 차단), 최종 게이트는 사람 승인(⑦)
개선	감사로그 축적 + TDD 정답셋(픽처처→기대 플래그) 회귀 체계 → 룰·프롬프트 개선의 피드백 기반

4.1 에이전트 파이프라인 (구현 완료)

콘텐츠 초안 입력 (한국어/영어 · 유형 자동/수동 · 8자 미만 스킵)

- ① 콘텐츠 유형 분류 예금·투자·대출 → 유형별 심의기준 라우팅
- ② 규제 근거 검색(RAG) 질의 확장 → 코퍼스 top-k 조항 (임계값 미달 시 "근거 불충분") ↴ 병렬
- ③ 룰엔진(결정적) 금지표현·필수고지·금리표기 - YAML 룰 10종, span 추출 ↴
- ④ LLM 심의(뉘앙스) ②근거+③결과 주입 → 위반가능성·표현리스크·수정안 (인용 제한) ↴ 병렬
- ⑤ ★오인 시뮬레이터 페르소나 5종(고령·초보·외국인 + 전북 농업인·소상공인) 역할극 → 오해 판정기 → 유발 문구 역추적 ↴
- ⑥ 리포트 종합 준법점수(감정식)·등급·하이라이트·인용을 한 화면에
- ⑦ 준법관리자 검토·승인 승인/반려/코멘트 (Human-in-the-loop)
- ⑧ 승인 후 배포가능 + 감사로그 + 다국어 생성·재심의


★ 준법 오토파일럿(F12) 위반 초안 → [①~⑥ 심의 + F7 를 치환 + LLM 재작성]을 통과/종료조건까지 자율 반복 (룰엔진이 합격 심판 → 환각 위장 불가 · 최종 게시는 ⑦ 사람 승인 · 자동개선 이력은 ⑧ 감사로그)

5 시스템 아키텍처 및 기술 스택



5.1 망분리(Air-gap) 아키텍처 — 3-zone

금융권 내부망/외부망 분리 원칙에 맞춘 배치. 심의 코어는 내부망에 격리되어 **심의 대상 데이터가 외부로 나가지 않으며**, 외부 연동은 모두 **망연계 게이트웨이(DMZ)**를 경유한다 — 실시간 크롤/직접 발송이 아니다.



데모는 어댑터를 목/피드로 구현해 동작을 증명하고, 운영 도입 시 이 게이트웨이 경유 연동·보안 검토(검역·단방향 전송)를 거친다.

레이어	선택	비고
LLM	Qwen2.5-7B-Instruct (Ollama 로컬 서빙)	한국어·다국어 강함, GPU 8-12GB. 14B 교체는 환경변수 1개
RAG	어휘 검색 기본 + BGE-m3 임베딩(선택 설치 시 자동 전환)	본선: Chroma/Qdrant 하이브리드
룰엔진	YAML + 정규식 (코드 수정 없이 룰 추가)	결정적·설명가능
백엔드/저장소	FastAPI(비동기 병렬) / SQLite	본선: PostgreSQL 전환 용이
프론트	정적 SPA (바닐라 JS)	1-커맨드 실행. 본선: Next.js 전환 계획

6 기능 명세 (구현 현황 포함)

ID	기능	입력 → 출력	상태
F1	콘텐츠 유형 분류	초안 → 예금/투자/대출 + 신뢰도	구현 ✓
F2	규제 근거 검색 (RAG)	초안+유형 → 관련 조항 top-k + 출처 + 유사도	구현 ✓
F3	롤엔진 심의	초안+유형 → 위반 룰(근거·심각도·위치·수정안)	구현 ✓
F4	LLM 심의	초안+F2+F3 → 뉘앙스 리스크·수정안 (인용 제한)	구현 ✓
F5	★소비자 오인 시물 레이터	초안+상품조건 → 페르소나별 오해·유발문구·조항	구현 ✓
F6	리포트 종합	F3~F5 → 준법점수·등급·하이라이트 통합 리포트	구현 ✓
F7	수정안 적용	수정안 선택 → 치환/고지 추가 + 자동 재심의	구현 ✓
F8	준법관리자 승인	리포트 → 승인/반려/코멘트 (Human-in-the-loop)	구현 ✓
F9	감사로그	모든 액션 → 누가/언제/근거 기록	구현 ✓
F10	다국어 생성+재심의 (+신뢰도 방어)	승인본 → 영문 버전 + 영문 룰셋 재심의(오역 검출). 한국어 우선 배포·다국어 후속. 재심의 불통과 시 알림 + 배포 보류 . 비-한/영 언어는 신뢰도 플래그 + 사람검토 권장	구현 ✓
F11	실시간 검사	입력 멈춤(1.2s)/붙여넣기 → 자동 심의	구현 ✓
F12	★준법 오토파일럿 (자율 개선 루프)	위반 초안 → 통과/종료조건까지 자율 반복 개선 + 회차별 근거 추적. 수정 전/후 비교 뷰 (diff) + 가독성 참고지표 (준법점수와 별개) 병행 표시	구현 ✓
F13	내부 심의기준(내규) 자연어→룰	평문 내규 → AI 룰 변환 → 법규와 함께 적용 (비개발자·[내규] 배지). 기존 법규 룰과 충돌 자동 탐지 (required↔forbidden 겹침 경고)	구현 ✓
F14	규제 자동 추적·영향 분석·룰 제안	규제 피드 변경 감지 → 영향 콘텐츠 분석 → 룰 자동 제안(사람 승인). 이미 승인·배포된 과거 콘텐츠 사후 재검사 (새 규제 영향분 탐지 → 재심의 알림)	구현 ✓
F15	마케팅 배포 Last-Mile	승인 콘텐츠 → 채널(푸시·SMS·이메일·SNS·CRM) 자동 연계 + 감사로그	구현 ✓
F16	상품 DB 연동	상품코드 → 전체 상품조건 자동 주입 (코어뱅킹 연동 슬롯)	구현 ✓
F17	유형 확장 (카드/이벤트/보험)	룰·체크리스트 확장	본선
F18	콘텐츠 큐 대시보드	리스크 등급 일람	본선

6.1 은행 제시 요구사항 매핑

은행이 제시한 내용	대응 기능
(기대㉠) 최신 규제+내부기준 자동 추적	F2 규제 지식베이스 + F14 규제 자동 추적 (피드 변경 감지→영향분석→룰 제안) + F13 내규 자연어→룰 . 운영: 법제처 OpenAPI 어댑터
(기대㉡) 위반가능성·표현리스크·수정제안 자동 도출	F3+F4 하이브리드 심의 → 등급·인라인 수정안 + F12 오토파일럿 자율 개선
(기대㉢) 준법관리자는 검토·승인 역할로 전환	F8 승인 워크스페이스 (AI 1차심의 → 사람 결정)
(기대㉣) 승인 결과의 프로세스 자동 연계	승인 → 배포가능 전환 + F9 감사추적 + F15 마케팅 Last-Mile (채널 자동 발송, 미승인 차단). 운영: FCM·SNS·SendGrid·알림톡 어댑터
(기능㉠) 규제 문서 검색·참조 근거 제공	F2 RAG — 모든 지적에 조항 출처 인용
(기능㉡) 다국어 이해 + 리스크 분류	F10 — 영문 룰셋 재심으로 오역·고지 누락 검출 + 비·한/영 신뢰도 방어
(기능㉢) 유형별 기준 구조화 + 룰+LLM 결합	F1 분류 라우팅 + F3 룰(결정적) + F4 LLM(취약성) + F16 상품DB 자동 주입

6.2 피드백 반영 개선 (2026-06 흐름 수정 · 구현 완료)

예선 후 검토 피드백을 반영해 6건을 추가 구현했다. 모두 **결정적(룰엔진 판정 권위 유지 · LLM 환각이 등급에 개입 못 함)**이며 LLM 미연결 시에도 동작한다.

개선	내용	대상 기능
전북 특화 페르소나	오인 시뮬레이터에 🏡 농업인 · 🏢 소상공인 추가 — 전북은행 고객 특성(계절성 목돈·운전자금·소상공인 비중) 반영	F5 시뮬레이터
수정 전/후 비교 뷰(diff)	오토파일럿 초안→최종을 어절 단위 diff(삭제 빨강·추가 초록)로 표시 — AI 수정 내역 파악·감사 추적 강화	F12 오토파일럿
가독성 참고지표	자동수정 완료 시 가독성 점수 1회 표시(문장 길이·전문용어 밀도). 준법 점수와 별개의 참고지표이며 마케팅 효과를 예측하지 않음 — 준법 통과만 추구할 때의 문장 경직을 작성자가 인지하도록 보조	F12 오토파일럿
내규·법규 충돌 탐지	내규를 룰로 변환한 직후 기존 법규 룰과 충돌(required↔forbidden 패턴 겹침) 자동 체크 → 경고. 수정·예외 적용은 사람 판단	F13 내규
승인 콘텐츠 사후 재검사	규제 변경 감지 시 이미 승인·배포된 과거 콘텐츠 중 새 규제 영향분을 자동 탐지 → "재심의 필요" 알림 (사후 관리)	F14 규제추적
다국어 재심의 불통과 알림	한국어 우선 배포 후 다국어 후속 생성·재심의. 재심의 불통과 시 마케터·준법감시인에 알림 + 외국어 채널 배포 보류(감사로그 기록)	F10 다국어

설계 판단 — 다국어 "일괄 배포" 미채택

피드백의 "전 언어 통과 후 일괄 배포(하나라도 걸리면 전체 보류)" 제안은 채택하지 않았다. 한국어가 주력 시장이고 다국어는 후속(한계비용≈0)이므로, 영어 재심의가 한국어 발송을 지연시키면 본 서비스의 핵심 가치(심의 리드타임 단축·마케팅 적시성)와 충돌한다. 대신 한국어 우선 배포 + 불통과 알림으로 우려를 해소했다.

7 MVP 구현 현황 및 검증

JB 준법 코파일럿
Compliance Copilot

메뉴

심의 워크스페이스

준법관리자 검토 2

심의 워크스페이스

예금 — 단정·원금보장 (메인 데모)

투자 — 손실고지 누락

대출 — 무조건 승인

예금 — 준법 통과 사례

영문 — 보장성 오역 (다국어 재심의)

베트남어 — 예금 보장성 (다국어)

중국어 — 예금 보장성 (다국어)

일본어 — 예금 보장성 (다국어)

유형: 예금·적금

한국어

내부 심의기준

재심의

확정 연 5%! 원금 보장 안심예금으로 노후를 준비하세요. 지금 가입하면 누구나 최고 금리 혜택!

v0.1.0 · MVP

온프레미스 · 오픈모델

Qwen2.5 · RAG · Rule Engine

수정안 전체 적용

준법 통과까지 자동 개선

검토 전송 →

준법 점수 47 / 100 · 위험

소비자는 이렇게 오해합니다

오인 내용 (3)

작성 시점에 취약 소비자(고령·금융초보·외국인)가 이 광고를 어떻게 오해하는지 미리 시뮬레이션합니다.

72세 은퇴자

위험

"확정 연 5%의 원금을 보장하는 안심예금으로 노후 자금을 준비할 수 있다는 것을 알았습니다."

오해

확정 연 5%의 원금 보장

← 유발 문구: "확정 연 5% 원금 보장 안심예금으로 노후를 준비하세요." (클릭해 본문 이동)

20대 금융초보

위험

"확정 연 5%의 원금 보장 예금으로 노후 준비를 할 수 있어요. 지금 가입하면 최고 금리를 받을 수 있습니다."

오해

확정 연 5%의 원금 보장 예금

← 유발 문구: "확정 연 5% 원금 보장 안심예금으로 노후를 준비하세요." (클릭해 본문 이동)

외국인 거주자

위험

"확정 연 5%의 원금을 보장하는 안심예금으로 노후 준비를 할 수 있다는 것과, 지금 가입하면 최고 금리 혜택을 받을 수 있다고 생각했습니다."

오해

확정 연 5%의 원금 보장

← 유발 문구: "확정 연 5% 원금 보장 안심예금으로 노후를 준비하세요." (클릭해 본문 이동)

준법 점수 47 · 위험

● 위반 2 ▲ 주의 3 ◆ 오인 3

유형 예금·적금

LLM · qwen2.5.7b-instruct

다국어 지원 (KO-EN-VI-ZH-JA) · RAG+Rule+LLM

MVP 실제 구동 화면 — 우측 헤드라인 「**소비자는 이렇게 오해합니다**」에 페르소나 3종의 1인칭 오해·유발 문구가 먼저 보이고(● 위험), 좌측 에디터엔 위험 문구 자동 밑줄, 하단 검토 결과엔 규제 출처 인용

- **실행:** `pip install -r requirements.txt && uvicorn app.main:app` 1분 구동. LLM 미연결 시 폴백 모드로 전 기능 시연 가능(평가 환경 의존성 제거).
- **자동 검증:** 테스트 **69건** 전체 통과 — TDD 정답셋(픽스처 5종 → 기대 룰 플래그), 유형 분류, 등급 판정, 수정 적용 후 점수 상승, 페르소나 오해 검출, 영문 오역 검출, 인용 제한, 초단문 스킵, 오토파일럿(수렴·종료보장·합격무결성·폴백), **내규 변환·규제 추적·배포·상품DB·다국어 신뢰도, 피드백 반영 6건(전북 페르소나·diff·가독성·충돌탐지·재검사·다국어 알림)**.
- **일관성:** 설계 문서(HTML) ↔ 본 기능명세서 ↔ 코드 ↔ 사용·로직 설명서가 동일한 기능 ID(F1~F18)·파이프라인 번호(①~⑥)로 정합.
- **문서 산출물:** 설계 문서 · 사용 설명서(PDF) · 로직 설명서(PDF) · README · 본 기능명세서.

자원	라이선스/출처	제약·검토사항
Qwen2.5-7B-Instruct	Apache 2.0 (Alibaba)	상업적 사용 가능. 금융권 도입 시 모델 거버넌스 평가 필요
Ollama	MIT	온프레미스 서빙, 외부 통신 없음
BGE-m3 (선택)	MIT (BAAI)	상업적 사용 가능
FastAPI / Uvicorn / PyYAML / httpx	MIT / BSD	—
법령 (금소법·표시광고법·자본시장법 등)	국가법령정보센터 — 법령은 저작권법 §7 비보호 저작물	MVP 코퍼스는 요약·재구성본 → 운영 시 원문 전문 수록·법무 검증
심사지침·협회 광고심의 규정	금융위·은행연합회·금융투자협회 공개 자료	요지 기반 룰화. 운영 도입 시 원문 대조 필요
JB 내부 심의 체크리스트	가상 데이터 (시연용 자체 작성)	실제 내규로 교체하는 슬롯 시연 목적 (F13 내규 기능으로 주입)
규제 변경 피드(reg_feed)·상품 카탈로그(products)	가상 데이터 (시연용)	F14는 법제처 OpenAPI, F16은 코어뱅킹 상품DB API로 교체하는 어댑터 슬롯
상용 API	사용 없음	대회 제약 및 온프레미스 원칙 준수

9

확장성 및 발전 경로

9.1 확장 축

축	확장 내용
계열사	전북은행·광주은행(은행 광고) → JB우리캐피탈(대출성 룰셋 재사용) → JB자산운용(투자광고 — 자본시장법 룰 이미 보유). 룰·코퍼스의 types 라우팅 구조가 그대로 확장 단위
콘텐츠 유형	카드·이벤트·보험(방카) — YAML 룰 추가만으로 확장 (F14)
언어	영어(구현) → 베트남어·중국어 — 전북 외국인 거주자 다수 언어. Qwen2.5 다국어 역량 활용
채널	웹 에디터(구현) → 사내 결재·CMS 플러그인, 콜센터 스크립트·상품설명서 심의

9.2 발전 경로 (PoC → 서비스화)

본선 (고도화)	F14 규제추적: 데모 피드 → 법제처 OpenAPI 실연동 · F15 배포: 실채널 API 연동
PoC	F16 상품DB: 코어뱅킹 실연동 · Qdrant 하이브리드 · 형태소 룰 매칭 · Next.js UI
파일럿	준법감시부와 과거 심의 사례 50~100건 블라인드 비교 (AI vs 사람 심의 일치율)
내부 적용	1개 부서 신규 콘텐츠에 병행 적용 → 검출률·시간 절감 측정, 룰 캘리브레이션
서비스화	전 계열사 광고심의 표준 도구화, 내규 코퍼스 정식 등재, 내부통제 보고 연계
	그룹 공통 'Compliance AI 플랫폼' - 콘텐츠 외 약관·스크립트·공시로 확대

리스크	대응 (구현됨 / 계획)
환각(허위 인용)	구현: 인용을 검색된 코퍼스 조항 id로 화이트리스트 제한 + 지적 문구의 원문 존재 검증 + 근거 부족 시 "근거 불충분" 명시
설명가능성	구현: 판정 빠대는 결정적 룰엔진(YAML 공개) + 모든 지적에 조항·출처 URL 인용 + 명시적 파이프라인(블랙박스 프레임워크 미사용)
책임소재	구현: AI=1차심의·권고, 사람=최종 승인 게이트. 결정 주체·시각·근거가 감사로그에 영구 기록. 준법 오토파일럿(F12)도 자동 게시 없이 pending 으로만 제출되며, AI 자동개선 이력과 사람 승인이 감사로그에 분리 기록됨
개인정보·보안	구현: 온프레미스·외부 전송 0 · 고객 개인정보 미취급. 계획: 접근권한 분리(작성자/승인자 역할), 로그 위변조 방지
저작권	구현: §8 라이선스 전수 점검 — 전 구성요소 상업적 사용 가능 라이선스
오탐/과탐 · 룰 유지 보수	입장: 룰엔진은 결정적 백본 이며 복잡한 예외를 100% 커버하는 게 목표가 아님 — 룰이 못 잡는 뉘앙스·예외는 ④ LLM 심의가 보완하는 이중 방어 이고, 근거가 약하면 '근거 불충분/저신뢰'로 솔직히 표기. 구현: 룰별 TDD 정답셋(픽스처=양성/음성 화귀), 내규 룰 테스트·미리보기(F13). 계획: 룰 커버리지 리포트 + 미탐 사례(LLM·사람이 잡은 것)를 신규 룰로 제안하는 피드백 루프, PoC 정밀도·재현율 캘리브레이션, 형태소 매칭(본선)
모델 노후화	구현: 모델 교체가 환경변수 1개(OLLAMA_MODEL) — 오픈모델 발전을 즉시 수용
비영어권 다국어 환각	구현: 비·한/영 언어는 language_confidence=low 플래그 + UI 경고 배너 + 사람검토 권장. 판정 권위는 언어별 룰셋(결정적) 이고 LLM은 참고용이라 환각이 등급을 좌우하지 못함. 계획: KO 피벗(외국어→한국어 번역 후 고자원 언어로 심의→매핑)으로 정밀도 보강
망분리 환경 ↔ 외부 연동	구조: 온프레미스는 "심의 코어(모델·데이터·룰)가 외부로 안 나감" 을 뜻하며 외부 연동 0이 아님. F14(규제 추적)·F15(배포)는 코어가 직접 크롤/발송하지 않고 망연계 게이트웨이(DMZ) 경유 — 규제 피드는 배치로 내부망 수신(실시간 크롤 아님), 승인본은 일방향으로 외부 발송계 전달. 심의 대상 데이터는 외부 유출 0 (§5 3-zone 아키텍처)
RAG 교차참조 누락	구현: 법률은 의미 유사성이 아닌 참조 트리(조→시행령→고시) 구조 → 참조 그래프 확장 (검색 조항이 참조하는 연계 규정을 맥락으로 추가). 또한 등급 권위는 RAG가 아니라 결정적 룰엔진 이라 RAG 오검색은 LLM '참고' 의견에만 영향, 등급은 못 흔들
내규 룰 생성 오류 (7B)	구현: 자연어→룰은 LLM이 제한만 하고 자동 적용 안 됨 — 정규식 컴파일 검증 + 사람 승인 게이트 통과해야 활성화 (권위=룰엔진+승인자). 적용 전 룰 테스트·미리보기(F13): 생성된 룰을 현재 초안에 돌려 과탐/미탐을 보여주므로, LLM이 정규식을 잘못 만들면(예: '최초'를 '최고'로) 사람이 적용 전에 발견. 기존 법규 룰과의 충돌(required↔forbidden 겹침)도 자동 탐지·경고. 되돌리기·토글·감사로그
승인 확증편향(자동화 함정)	구현: 승인 전 AI 불확실·플랙 경고 + "원문 직접 검토" 확인 강제 + "AI는 보조, 최종 책임은 검토자" 명시. AI 단독 지적은 advisory로 분리해 무지성 승인을 억제
오인 시뮬레이터 과잉규제	구현: 시뮬레이터 오해는 법적 판정이 아닌 참고지표 로 명시 라벨 — 준법 등급은 규정(룰엔진) 기준. 룰이 깨끗하면 페르소나만으로 반려/위험 강등되지 않음(advisory 분리). "합법이지만 오해 유발"은 반려가 아니라 표현 개선 권고
마케팅 가치 훼손	구현: 오토파일럿 수정 에이전트는 "핵심 셀링포인트 보존" 제약. 오토파일럿은 선택이며 결과는 사람 승인을 거쳐 교정 시 반려 가능. 자동수정 후 가독성 참고지표 (문장 길이·전문용어 밀도)를 1회 표시해 문장 경직을 작성자가 인지 (준법점수와 별개·마케팅 효과 예측 아님). 계획: 소구력 포함 "통과+효과" 파레토 최적화(본선)

11 한계 및 향후 계획

- 규제 코퍼스는 큐레이션 서브셋(12조항) → 전체 규제·내규 확장 및 법무 검증 필요.
- 페르소나 3종은 대표 취약 유형 → 실제 고객 세그먼트 데이터 기반 정교화 가능.

- 준법점수 가중치는 휴리스틱 → 실제 심의 데이터로 캘리브레이션 예정.
- 실제 제재 사례 코퍼스(판례형 근거) 추가 시 설득력 강화.
- 준법 오토파일럿(F12)의 LLM 재작성 품질은 모델 의존적 → 룰엔진 합격 검증·최대 회차 상한·사람 승인으로 가드. 7B는 CPU에서 회차당 지연이 있어 GPU 권장.

12 부록 A — 시연 시나리오 (90초 영상 콘티)

구간	화면	내레이션 요지
0:00–0:08	"확정 연 5%! 원금 보장 안심예금..." 붙여넣기 → 우측 헤드라인 「 👤 소비자는 이렇게 오해합니다 」에 즉시 반응	"광고를 붙여넣는 순간, 가장 먼저 보이는 건 위반 목록이 아니라—소비자의 반응입니다."
0:08–0:24	★ 헤드라인 : 페르소나 3종 리액션 카드 쏘임 — 🗣️ 말풍선 "원금 보장이니 안전하겠네" → 🔴 오해 + ⬅️ 유발 문구. 😓 20대·🌐 외국인도 각자 오해	"핵심 차별점입니다. 72세 은퇴자, 20대 초보, 외국인이 이 광고를 실제로 어떻게 오해하는지 작성 시점에 1인칭으로 재현합니다. 규제の本질은 '오인 방지'니까요."
0:24–0:36	그 오해가 왜 생기는지 — 위험 문구 자동 밑줄 + 우측 금소법 §22 등 인용 지적, 🔴 점수	"오해를 유발한 문구마다 규제 조항 출처가 붙습니다. 결정적 룰엔진이 근거를 보장합니다."
0:36–0:55	[🚀 준법 통과까지 자동 개선] → 점수 게이지 자율 상승 🔴 46→🟡 82→🟢 88, 회차별 수정 타임라인(규제 근거)	"'자동 개선'을 누르면 에이전트가 통과까지 스스로 고쳐 씁니다. 합격 판정은 룰엔진이 검증해 환각을 차단합니다."
0:55–1:08	검토 전송 → 승인 뷰: 감사로그에 [AI-오토파일럿 자동개선] + [사람 승인] 분리 기록 → ✓ 승인	"자율 개선해도 게시는 사람 몫. 'AI가 무엇을 고쳤고 사람이 무엇을 승인했는지'가 분리 기록됩니다."
1:08–1:22	내부 심의기준(내규) : 평문 "'업계 최초' 표현 금지" 입력 → [AI로 룰 변환] → [내규] 배지로 법규와 함께 검출	"법규는 기본 탑재. 우리 기관 내규를 자연어로 적으면 AI가 룰로 바꿔 함께 적용합니다. 코드가 필요 없습니다."
1:22–1:35	[영문 버전 생성+재심의]: 'Guaranteed' 검출 화면	"승인본의 영문 버전을 만들고 재심의—번역에서 생긴 보장성 오역까지 잡아냅니다. 전 과정 온프레미스."

13 부록 B — 평가항목 대응표

평가항목	본 제출물에서의 위치
1. 주제적합성·문제정의	§1 (지정주제2 직접 대응 · 사용자/상황 · 은행 제시 현행/한계 · JB 관점 중요도 · 과제 전환성)
2. 업무 연계성·고객가치	§2 (As-Is/To-Be 접점 · 기대효과 4축 · 규제/보안/내부통제 · AX 부합)
3. Agent 설계·구현 가능성	§4 (판단·행동·검증·개선 구조) · §5 (아키텍처/스택) · §8 (출처·라이선스) — 전부 동작 코드로 실증
4. MVP 완성도·검증	§6 (기능 F1~F16 구현 ✓ · 6.2 피드백 반영 6건) · §7 (테스트 69건·1분 구동·문서 정합) · §9 (본선 기반)
5. 혁신성·확장성·리스크	§3 (차별점) · §9 (계열사/유형/언어 확장 + PoC→서비스화 경로) · §10 (환각·설명가능성·책임소재 등)
+ 시연영상	§12 콘티 — MVP에서 그대로 촬영 가능 (전 장면 구현 완료)

